

DeepLabV3 ve VGG19 Kullanılarak İnsan Bölgesini Koruyan Semantik Destekli Neural Style Transfer

Burak İlyas Şahin
Yapay Zeka Mühendisliği
Ostim Teknik Üniversitesi
3.Sınıf Öğrencisi
Ankara, Türkiye
230212039@gmail.com

Özet—NST, bir içerik görüntüsünün yapısal bilgisini korurken başka bir görüntünün sanatsal stilini aktarmayı amaçlayan önemli bir görüntü üretim yöntemidir. Ancak klasik NST yaklaşımında stil aktarımı tüm görüntü üzerine uygulandığı için insan içeren fotoğraflarda yüz, vücut, kıyafet ve ten bölgesinde doğal olmayan bozulmalar oluşabilmektedir. Bu çalışmada, bu problemi azaltmak amacıyla DeepLabV3 tabanlı kişi segmentasyonu ile VGG19 tabanlı optimizasyon temelli Neural Style Transfer yöntemi birleştirilmiştir. Önerilen sistemde öncelikle içerik görüntüsündeki insan bölgesi semantik segmentasyon ile tespit edilmekte, ardından VGG19 ara katmanlarından çıkarılan içerik ve stil temsilleri kullanılarak tam görüntü üzerinde stil aktarımı yapılmaktadır. Son aşamada, insan maskesi Gaussian bulanıklaştırma ile yumuşatılarak orijinal insan bölgesi ile stilize edilmiş arka plan harmanlanmaktadır. Böylece klasik NST sonucuna kıyasla insan bölgesi daha yüksek oranda korunurken arka planda sanatsal dönüşüm elde edilmektedir. Çalışmada içerik kaybı, stil kaybı, Gram matrisi, toplam varyasyon kaybı, PSNR, SSIM, MSE ve kişi bölgesi MSE metrikleri matematiksel olarak ele alınmıştır. Deneysel değerlendirme, görüntü boyutu, optimizasyon adımı, içerik ağırlığı, stil ağırlığı, öğrenme oranı ve maske bulanıklaştırma parametrelerinin sonuç üzerindeki etkisini tartışmaktadır. Sonuçlar, semantik maskeleye yaklaşımının özellikle insan odaklı görsellerde klasik NST'ye göre daha kontrollü ve görsel olarak daha anlamlı çıktılar üretebildiğini göstermektedir.

Index Terms—Neural Style Transfer, Semantic Segmentation, DeepLabV3, VGG19, Computer Vision, PyTorch.

I. GİRİŞ

A. Görüntü Ön İşleme

Görüntü işleme ve derin öğrenme alanındaki gelişmeler, yalnızca görüntü sınıflandırma veya nesne tespiti gibi analitik görevlerde değil, aynı zamanda üretici ve dönüştürücü görsel uygulamalarda da önemli ilerlemeler sağlamıştır. Neural Style Transfer, bu bağlamda bir içerik görüntüsünün sahne yapısını korurken başka bir stil görüntüsünün renk, doku ve fırça izi karakteristiğini aktaran bir yöntemdir. Gatys vd. tarafından önerilen temel NST yaklaşımı, evrimsel sinir ağlarının ara katman temsillerini kullanarak içerik ve stil bilgisini ayırtırmayı mümkün kılmıştır. Bu yaklaşımda içerik bilgisi derin katmanlardaki özellik haritalarıyla, stil bilgisi ise farklı katmanlardaki özellik haritalarının korelasyonlarını ifade eden Gram matrisleriyle temsil edilir.



Şekil 1. Semantic Style Transfer sonuçlarının karşılaştırılması: içerik görüntüsü, stil görüntüsü, klasik NST çıktısı ve insan bölgesini koruyan semantik NST çıktısı. Detaylı sonuç görselleri proje GitHub deposunda ulaşılabilir. Sayın halk ozanımız Neşet Ertaş' ı saygı ve rahmetle anıyoruz.

Klasik NST yaklaşımı sanatsal açıdan başarılı sonuçlar üretmesine rağmen, tüm görüntüyü tek bir bütün olarak ele aldığı için semantik olarak önemli bölgeleri ayırt edemez. Örneğin insan içeren bir fotoğrafta yüz, saç, kıyafet veya vücut bölgesi de arka planla aynı yoğunlukta stilize edilir. Bu durum özellikle portre, sosyal medya fotoğrafı veya insan odaklı görsellerde istenmeyen bozulmalara yol açar. Bir insan fotoğrafında arka planın sanatsal biçimde dönüştürülmesi istenirken kişinin yüz detaylarının korunması çoğu kullanım senaryosu için daha anlamlıdır. Bu problem, klasik NST'nin semantik farkındalık eksikliğinden kaynaklanmaktadır.

Bu çalışmada geliştirilen proje, klasik Neural Style Transfer yöntemini semantik segmentasyon ile destekleyerek insan bölgesini koruyan bir stil aktarım hattı sunmaktadır. Projede iki temel derin öğrenme modeli kullanılmıştır. İlk olarak VGG19 modeli, içerik ve stil temsillerini çıkarmak için sabit özellik çıkarıcı olarak kullanılmaktadır. İkinci olarak DeepLabV3-

ResNet50 modeli, içerik görüntüsündeki insan sınıfını tahmin etmek ve kişi maskesi üretmek için kullanılmaktadır. Elde edilen maske, stil aktarımı sonucunun yalnızca arka plan kısmında baskın olmasını sağlayan bir harmanlama mekanizmasına dönüştürülmektedir.

Bu projenin temel katkısı, hazır modelleri yalnızca doğrudan kullanmak değil, bu modellerin görevlerini anlamlı bir bilgisayarlı görü hattı içinde birleştirmektir. VGG19 modeli görüntünün algısal temsiliyi çıkarırken, DeepLabV3 modeli görüntünün semantik bölgelere ayrılmasını sağlar. Bu iki farklı yaklaşımın birleşimi, hem sanatsal dönüşüm hem de nesne/kişi koruma hedeflerini aynı sistemde toplamaktadır.

II. PROBLEM TANIMI VE MOTIVASYON

Klasik Neural Style Transfer problemi, verilen bir içerik görüntüsü I_c ve stil görüntüsü I_s için yeni bir çıktı görüntüsü I_t üretmeyi amaçlar. Bu çıktı görüntüsünün içerik açısından I_c 'ye, stil açısından ise I_s 'ye benzemesi beklenir. Bu problem şu şekilde ifade edilebilir:

$$I_t^* = \arg \min_{I_t} (\alpha \mathcal{L}_{content}(I_t, I_c) + \beta \mathcal{L}_{style}(I_t, I_s)) \quad (1)$$

Burada α içerik koruma ağırlığını, β ise stil aktarımı ağırlığını temsil eder. Ancak bu ifade, görüntüdeki farklı semantik bölgeler arasında ayırım yapmaz. Dolayısıyla insan, bina, gökyüzü veya arka plan gibi bölgeler aynı şekilde optimize edilir. İnsan içeren görsellerde bu durum önemli bir problemidir; çünkü insan yüzü ve vücudu görsel algı açısından en hassas bölgelerdendir. Küçük renk veya doku değişimleri bile kişinin tanınabilirliğini ve doğrallığını bozabilir.

Bu çalışmada problem, yalnızca tüm görüntüyü stilize etmek olarak değil, insan bölgesini koruyarak arka planı stilize etmek olarak yeniden tanımlanmıştır. Buna göre hedef çıktı görüntüsü I_{sem} şu özellikleri taşımalıdır:

- Arka plan bölgesi stil görüntüsünün renk ve doku özelliklerini taşımalıdır.
- İnsan bölgesi orijinal içerik görüntüsüne mümkün olduğunca yakın kalmalıdır.
- İnsan ile arka plan arasındaki geçiş keskin ve yapay görünmemelidir.
- Sonuç görüntüsü hem içerik bütünlüğünü hem de sanatsal stil etkisini korumalıdır.

Bu hedef doğrultusunda semantik segmentasyon destekli bir harmanlama yaklaşımı kullanılmıştır. Klasik NST çıktısı doğrudan nihai sonuç olarak alınmamış, bunun yerine kişi maskesi aracılığıyla orijinal içerik görüntüsüyle birleştirilmiştir. Bu yaklaşım, özellikle insan fotoğraflarında klasik NST'ye göre daha kontrollü sonuç üretmeyi amaçlar.

III. LİTERATÜR VE TEORİK ARKA PLAN

A. Neural Style Transfer

Neural Style Transfer, derin evrimsel sinir ağlarının görüntülerden çıkardığı ara temsillerin yalnızca sınıflandırma için değil, görüntü sentezi için de kullanılabileceğini göstermiştir. Gatys vd. tarafından önerilen yöntemde, ImageNet üzerinde

eğitilmiş VGG ağı sabit bir özellik çıkarıcı olarak kullanılır. Bu yöntemde ağı derin katmanları nesne ve sahne düzeni gibi içerik bilgisini, daha sık ve orta katmanları ise renk, desen ve doku gibi stil bilgisini temsil etmek için kullanılır.

NST'nin güçlü tarafı, herhangi bir yeni veri setiyle model eğitmeye gerek duymadan, tek bir içerik ve tek bir stil görüntüsü üzerinden optimizasyon yapılabilmesidir. Bununla birlikte, optimizasyon temelli olması nedeniyle işlem süresi yüksektir. Her yeni içerik stil çifti için çıktı görüntüsü yeniden optimize edilir. Bu durum, raporda özellikle vurgulanmalıdır: Bu projede VGG19 veya DeepLabV3 sıfırdan eğitilmemiştir; hazır ağırlıklar kullanılmış, çıktı görüntüsü ise iteratif optimizasyon ile üretilmiştir.

B. VGG19 ile Özellik Çıkarımı

VGG19 mimarisi, küçük 3×3 evrişim filtrelerini derin bir ağ yapısında ardışık şekilde kullanarak güçlü görüntü temsilleri elde eden bir CNN mimarisidir. Bu çalışmada VGG19 sınıflandırma amacıyla değil, özellik çıkarıcı olarak kullanılmıştır. Ağı parametreleri dondurulmuş ve yalnızca hedef görüntü optimize edilmiştir.

Projede stil kaybı için aşağıdaki VGG19 katmanları kullanılmıştır:

Tablo I
STİL VE İÇERİK TEMSİLİ İÇİN KULLANILAN VGG19 KATMANLARI

Amaç	Katman İndeksi	Katman Adı
Stil	0	conv1_1
Stil	5	conv2_1
Stil	10	conv3_1
Stil	19	conv4_1
Stil	28	conv5_1
İçerik	21	conv4_2

Bu katman seçimi NST literatürüyle uyumludur. Sık katmanlar kenar, renk geçişi ve düşük seviye dokuları yakalarken, daha derin katmanlar daha soyut ve geniş bağlamli temsiller üretir. İçerik için conv4_2 katmanının seçilmesi, görüntünün piksel seviyesindeki ayrıntılarından ziyade sahne ve nesne yerleşiminin korunmasını sağlar.

C. Semantik Segmentasyon ve DeepLabV3

Semantik segmentasyon, görüntüdeki her pikselin bir sınıfa atanması problemidir. Bu proje kapsamında semantik segmentasyonun amacı, içerik görüntüsündeki insan bölgesini tespit etmektir. DeepLabV3, atrous convolution kullanarak özellik haritalarının çözünürlüğünü kontrol eder ve farklı ölçeklerde bağlam bilgisini yakalayabilir. Bu nedenle kişi bölgesi gibi nesne sınırlarının belirlenmesinde uygun bir hazır modeldir.

Projede kullanılan DeepLabV3-ResNet50 modeli, hazır ağırlıklarla yüklenmiş ve modelin kategori listesinden "person" sınıfı seçilmiştir. Segmentasyon çıktısında her piksel için en yüksek olasılıklı sınıf alınmış, ardından person sınıfına ait piksellerden ikili maske oluşturulmuştur. Maske üzerinde morfolojik açma ve kapama işlemleri uygulanarak küçük görüntüler azaltılmıştır.

IV. ÖNERİLEN YÖNTEM

A. Genel Sistem Akışı

Önerilen sistem, içerik görüntüsü ve stil görüntüsünü girdi olarak alır. Sistem akışı aşağıdaki adımlardan oluşur:

- 1) İçerik ve stil görüntüleri belirlenen boyuta yeniden ölçeklenir.
- 2) İçerik görüntüsü DeepLabV3 modeline verilerek kişi maskesi çıkarılır.
- 3) İçerik ve stil görüntüleri VGG19 tabanlı NST sürecine alınır.
- 4) Hedef görüntü, içerik ve stil kayıplarına göre iteratif olarak optimize edilir.
- 5) Elde edilen tam stilize görüntü, kişi maskesi kullanılarak orijinal içerik görüntüsüyle harmanlanır.
- 6) Nihai semantik stil aktarımı sonucu, insan bölgesini daha doğal koruyacak biçimde üretilir.

Girdi görüntüleri RGB formatına dönüştürülür ve modelin işlem kararlılığı açısından sabit bir boyuta yeniden ölçeklenir. Projede hızlı testler için 256×256 , dengeli kullanım için 384×384 , daha yüksek kalite için ise 512×512 boyutları önerilmektedir. Görüntü boyutu arttıkça hem VGG19 özellik haritalarının boyutu hem de optimize edilen hedef tensörün parametre sayısı artar. Bu durum görsel kaliteyi artırabilse de bellek kullanımı ve işlem süresini yükseltir.

VGG19 modeline giriş verilmeden önce ImageNet normalizasyonu uygulanır. Bir piksel tensörü X için normalize edilmiş tensör şu şekilde hesaplanır:

$$\hat{X}_{c,h,w} = \frac{X_{c,h,w} - \mu_c}{\sigma_c} \quad (2)$$

Burada $\mu = [0.485, 0.456, 0.406]$ ve $\sigma = [0.229, 0.224, 0.225]$ ImageNet veri seti için kullanılan kanal ortalaması ve standart sapmasıdır. Bu normalizasyon, hazır VGG19 ağırlıklarının beklediği giriş dağılımına yaklaşmak için gereklidir.

B. İçerik Kaybı

İçerik kaybı, hedef görüntünün VGG19 ara katmanındaki özellik temsili ile içerik görüntüsünün aynı katmandaki özellik temsili arasındaki farkı ölçer. VGG19'un l katmanındaki özellik çıkarma fonksiyonu $\phi_l(\cdot)$ ile gösterilsin. İçerik kaybı şu şekilde tanımlanır:

$$\mathcal{L}_{content}(I_t, I_c) = \frac{1}{N_l} \|\phi_l(I_t) - \phi_l(I_c)\|_2^2 \quad (3)$$

Bu projede içerik katmanı olarak conv4_2 kullanılmıştır. Daha sık bir katman seçilseydi piksel ve kenar benzerliği daha güçlü korunabilirdi; ancak bu durumda stil aktarımı daha sınırlı kalabilirdi. Daha derin bir katman seçilseydi sahne yapısı daha soyut korunur, fakat detay kaybı artabilirdi. conv4_2 bu nedenle literatürde sık kullanılan dengeli bir seçimdir.

C. Gram Matrisi ve Stil Kaybı

Stil bilgisini temsil etmek için Gram matrisi kullanılmıştır. Bir katmandaki özellik haritası $F^l \in \mathbb{R}^{C_l \times H_l \times W_l}$ olsun. Bu özellik haritası $C_l \times (H_l W_l)$ boyutuna dönüştürülerek Gram matrisi şu şekilde hesaplanır:

$$G^l = \frac{F^l (F^l)^T}{C_l H_l W_l} \quad (4)$$

Gram matrisi, farklı kanal aktivasyonları arasındaki korelasyonları ölçer. Bu korelasyonlar görüntüdeki doku, renk dağılımı ve tekrar eden desen gibi stil özelliklerini temsil eder. Stil kaybı, hedef görüntünün Gram matrisi ile stil görüntüsünün Gram matrisi arasındaki farkların toplamıdır:

$$\mathcal{L}_{style}(I_t, I_s) = \sum_{l \in \mathcal{S}} w_l \|G^l(I_t) - G^l(I_s)\|_2^2 \quad (5)$$

Burada $\mathcal{S}$ stil katmanları kümesini, w_l ise her stil katmanının ağırlığını temsil eder. Projede stil katman ağırlıkları conv1_1 için 1.0, conv2_1 için 0.8, conv3_1 için 0.5, conv4_1 için 0.3 ve conv5_1 için 0.1 olarak belirlenmiştir. Bu dağılım, sık katmanlardaki doku ve renk bilgisini daha baskın tutarken, derin katmanların daha soyut stil katkısını sınırlı tutar.

D. Toplam Varyasyon Kaybı

Optimizasyon sürecinde hedef görüntüde keskin ve rastgele piksel gürültüleri oluşabilir. Bu etkiyi azaltmak için toplam varyasyon kaybı kullanılmıştır. Toplam varyasyon kaybı, komşu pikseller arasındaki ani değişimleri cezalandırır:

$$\mathcal{L}_{tv}(I_t) = \sum_{i,j} |I_{t,i,j} - I_{t,i,j+1}| + |I_{t,i,j} - I_{t,i+1,j}| \quad (6)$$

Projede toplam varyasyon kaybı düşük bir katsayıyla, $\gamma = 10^{-6}$ düzeyinde kullanılmıştır. Bu değer, stil aktarımını baskılamadan çıktının daha pürüzsüz görünmesine yardımcı olur.

E. Toplam Optimizasyon Fonksiyonu

Tüm kayıplar birleştirildiğinde toplam amaç fonksiyonu şu şekilde ifade edilir:

$$\mathcal{L}_{total} = \alpha \mathcal{L}_{content} + \beta \mathcal{L}_{style} + \gamma \mathcal{L}_{tv} \quad (7)$$

Burada α içerik ağırlığı, β stil ağırlığı, γ ise toplam varyasyon ağırlığıdır. Projede başlangıç için $\alpha = 5.0$, $\beta = 100000.0$ ve $\gamma = 10^{-6}$ kullanılmıştır. Stil kaybının sayısal ölçeği içerik kaybından farklı olduğu için stil ağırlığının çok daha büyük seçilmesi normaldir. Bu değer doğrudan “stilin içerikten 20000 kat önemli olduğu” anlamına gelmez; çünkü kayıp terimlerinin ham büyüklükleri farklıdır.

Hedef görüntü başlangıçta içerik görüntüsünün kopyası olarak alınır. Daha sonra Adam optimizasyon algoritması ile hedef görüntünün piksel değerleri güncellenir. Bu süreçte VGG19 modeli eğitilmez; yalnızca hedef görüntü tensörü optimize edilir. Bu ayrım rapor açısından önemlidir, çünkü çalışma bir model eğitimi değil, optimizasyon tabanlı görüntü sentezidir.



Şekil 2. Maskeleme İşlemi

F. Kişi Maskesi Üretimi

DeepLabV3 modeli içerik görüntüsündeki her piksel için sınıf tahmini üretir. Tahmin edilen sınıf haritası P ile gösterilirse, kişi maskesi M şu şekilde tanımlanır:

$$M(i, j) = \begin{cases} 1, & P(i, j) = \text{person} \\ 0, & \text{aksi halde} \end{cases} \quad (8)$$

Bu ikili maske doğrudan kullanıldığında insan ve arka plan arasında keskin geçişler oluşabilir. Bu nedenle maske önce morfolojik açma/kapama işlemlerinden geçirilir, ardından Gaussian bulanıklaştırma uygulanarak yumuşatılmış maske $\tilde{M}$ elde edilir. Açma işlemi küçük beyaz gürültüleri azaltırken, kapama işlemi maske içindeki küçük boşlukları kapatır. Gaussian bulanıklaştırma ise geçiş bölgelerini daha doğal hale getirir.

G. Semantik Harmanlama

Tam NST sonucunda elde edilen stilize görüntü I_{nst} , orijinal içerik görüntüsü I_c ve yumuşatılmış kişi maskesi $\tilde{M}$ kullanılarak nihai semantik çıktı üretilir:

$$I_{sem} = \tilde{M} \odot I_c + (1 - \tilde{M}) \odot I_{nst} \quad (9)$$

Burada $\odot$ eleman bazlı çarpımı ifade eder. $\tilde{M}$ değeri insan bölgesinde 1'e yakın olduğu için bu bölgelerde orijinal içerik görüntüsü korunur. Arka planda $\tilde{M}$ değeri 0'a yakındır ve bu bölgelerde stilize görüntü baskın olur. Maske sınırlarında ise iki görüntü kademeli olarak karışır. Bu sayede keskin keski yapıştır etkisi azaltılır.

V. UYGULAMA MIMARISI

Proje Python tabanlı, nesne yönelimli ve modüler bir yapıda geliştirilmiştir. Kod yapısında her modül farklı bir sorumluluğa sahiptir. Bu yapı, projenin okunabilirliğini ve geliştirilebilirliğini artırır.

Şekil 3. Arayüz Fotoğraflarına /bilyas0 Github Hesabın üzerinden ulaşılabilirsiniz.

Tablo II
PROJE DOSYALARININ GÖREVLERİ

Dosya	Görev
app.py	Streamlit kullanıcı arayüzünü çalıştırır.
main.py	Terminal üzerinden içerik ve stil görüntüsüyle çalıştırma sağlar.
image_utils.py	Görüntü okuma, tensöre çevirme, NumPy/PIL dönüşümleri ve kaydetme işlemlerini yönetir.
segmenter.py	DeepLabV3-ResNet50 ile kişi maskesi üretir.
nst_model.py	VGG19 tabanlı NST kayıplarını ve optimizasyon döngüsünü içerir.
semantic_style_transfer.py	İçerik ve stil hatlarını birleştirir; NST, maskeleme, harmanlama ve metrik hesaplama yapar.

Kullanılan temel kütüphaneler PyTorch, TorchVision, NumPy, OpenCV, Pillow, scikit-image, Matplotlib ve Streamlit'tir. PyTorch ve TorchVision model yükleme ve tensör işlemlerinde, OpenCV maske temizleme ve Gaussian blur işlemlerinde, scikit-image ise PSNR ve SSIM gibi metriklerin hesaplanmasında kullanılmıştır.

VI. DENEYSEL KURULUM

A. Donanım ve Yazılım Ortamı

Deneyler Google Colab veya CUDA destekli yerel bir bilgisayar üzerinde çalıştırılabilecek şekilde tasarlanmıştır. GPU kullanımı özellikle NST optimizasyonu için önemlidir; çünkü her iterasyonda VGG19 üzerinden ileri yayılım yapılmakta ve hedef görüntü için geriye yayılım hesaplanmaktadır. CPU üzerinde de çalışmak mümkündür, ancak işlem süresi belirgin biçimde artar.

Tablo III
DENEYSEL ORTAM BİLGİLERİ İÇİN DOLDURULACAK TABLO

Özellik	Değer
Programlama dili	Python 3.x
Derin öğrenme kütüphanesi	PyTorch
Görüntü işleme	OpenCV, Pillow
Metrikler	scikit-image
Arayüz	Streamlit
Donanım	Google Colab GPU / Yerel GPU
GPU tipi	Buraya Colab çıktısı eklenecek
Görüntü boyutu	256, 384, 512

B. Deney Parametreleri

Bu çalışmada temel olarak altı parametrenin sonuç üzerindeki etkisi incelenmiştir: görüntü boyutu, optimizasyon adım sayısı, içerik ağırlığı, stil ağırlığı, öğrenme oranı ve maske bulanıklaştırma boyutu.

Tablo IV
PARAMETRELERİN ANLAMI VE BEKLENEN ETKİLERİ

Parametre	Etki
Image Size	Çözünürlük ve hesaplama maliyetini belirler. Artarsa detay artabilir ancak süre ve bellek kullanımı yükselir.
Steps	Optimizasyon adım sayısıdır. Artarsa stil daha belirgin olabilir; çok artarsa süre uzar ve bazı durumlarda aşırı stilizasyon oluşur.
Content Weight	İçerik yapısını koruma etkisini artırır. Çok yüksek olursa stil zayıflar.
Style Weight	Stil dokusunun baskınlığını artırır. Çok yüksek olursa insan sınırlarında ve arka planda bozulmalar artabilir.
Learning Rate	Hedef görüntünün güncellenme hızını belirler. Çok yüksek olursa kararsızlık, çok düşük olursa yavaş yakınsama görülebilir.
Blur Size	İnsan maskesi ile arka plan arasındaki geçişi yumuşatır. Çok düşük olursa keskin sınır, çok yüksek olursa insan kenarlarında stil sızması görülebilir.

C. Önerilen Parametre Deneyleri

Parametre denemeleri açısından, raporda yalnızca tek bir sonuç göstermek yeterli değildir. Bu nedenle aşağıdaki deney planı önerilmektedir. Önce düşük çözünürlükte hızlı denemeler yapılmalı, en dengeli parametre grubu belirlendikten sonra daha yüksek adım sayısı veya çözünürlük ile final sonuç üretilmelidir. Bu bizim için önemli olduğunu düşünmekteyiz.

Tablo V
DENEY PLANI VE PARAMETRE KOMBİNASYONLARI

Deney	Boyut	Step	α	β	Blur	Amaç
D1	256	80	5	100000	21	Hızlı ön test
D2	384	150	5	100000	21	Dengeli temel sonuç
D3	384	300	5	100000	21	Daha fazla optimizasyon etkisi
D4	512	300	5	100000	21	Yüksek kalite testi
D5	384	150	10	50000	21	İçerik koruma ağırlıklı test
D6	384	150	3	200000	21	Stil baskın test
D7	384	150	5	100000	7	Keskin maske geçişi
D8	384	150	5	100000	41	Yumuşak maske geçişi

Bu tablo raporda önemlidir; çünkü proje yalnızca kodun çalıştırılmasından ibaret değildir. Yapay zeka mühendisliği bakış açısıyla model davranışının parametreler üzerinden analiz edildiğini gösterir.

VII. DEĞERLENDİRME METRİKLERİ

A. MSE

Mean Squared Error (MSE), referans görüntü ile çıktı görüntüsü arasındaki ortalama karesel piksel farkını ölçer:

$$MSE = \frac{1}{HWC} \sum_{i=1}^H \sum_{j=1}^W \sum_{c=1}^C (I(i, j, c) - \hat{I}(i, j, c))^2 \quad (10)$$

MSE düşükse çıktı görüntüsü referans görüntüye piksel bazında daha yakındır. Ancak NST gibi sanatsal dönüşüm problemlerinde MSE tek başına başarı ölçütü değildir. Çünkü stil aktarımı bilinçli olarak piksel değerlerini değiştirir. Bu nedenle MSE özellikle insan bölgesinin korunup korunmadığını analiz ederken daha anlamlıdır.

B. PSNR

Peak Signal-to-Noise Ratio (PSNR), MSE değerinden türetilen ve görüntü benzerliğini desibel cinsinden ifade eden bir metriktir:

$$PSNR = 10 \log_{10} \left(\frac{MAX_I^2}{MSE} \right) \quad (11)$$

Normalize edilmiş görüntülerde $MAX_I = 1$ alınabilir. PSNR değeri yükseldikçe çıktı görüntüsü referansa daha yakındır. Semantik NST sonucunda özellikle insan bölgesi korunduğu için, klasik full NST sonucuna göre PSNR'nin artması beklenebilir. Fakat arka plan bilinçli olarak değiştirildiği için PSNR'nin çok yüksek olması her zaman daha iyi stil aktarımı anlamına gelmez.

C. SSIM

Structural Similarity Index Measure (SSIM), iki görüntü arasındaki parlaklık, kontrast ve yapısal benzerliği birlikte değerlendirir. Genel formu şu şekildedir:

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (12)$$

SSIM değeri 1'e yaklaştıkça yapısal benzerlik artar. Bu çalışmada SSIM, özellikle semantik harmanlama sonucunun içerik görüntüsüne yapısal olarak ne kadar yakın kaldığını değerlendirmek için kullanılmıştır.

D. Person MSE

Projeye özgü en önemli metriklerden biri kişi bölgesi MSE değeridir. Bu metrik yalnızca DeepLabV3 ile tespit edilen insan maskesi içindeki farkı ölçer:

$$MSE_{person} = \frac{\sum ((I_c - I_o)^2 \odot M)}{\sum M + \epsilon} \quad (13)$$

Burada I_o çıktı görüntüsünü, M kişi maskesini, ϵ ise sıfıra bölmeyi engelleyen küçük sabiti ifade eder. Semantik NST yönteminin temel amacı insan bölgesini korumak olduğundan, klasik full NST sonucuna göre MSE_{person} değerinin belirgin şekilde düşmesi beklenir. Bu nedenle raporda en kritik nicel karşılaştırma full NST ve semantic NST arasındaki person MSE farkıdır.

VIII. DENEYSEL SONUÇLAR VE TARTIŞMA

A. Klasik NST ve Semantik NST Karşılaştırması

Klasik full NST sonucunda stil tüm görüntüye uygulandığı için insan bölgesinde renk ve doku değişimleri oluşmaktadır. Bu sonuç sanatsal açıdan güçlü görünebilir; ancak insan fotoğrafı bağlamında kişinin yüz, ten ve kıyafet detaylarını bozduğu için her zaman tercih edilebilir değildir. Semantik NST sonucunda ise arka plan stilize edilirken insan bölgesi büyük ölçüde orijinal görüntüden korunmaktadır.

Bu görsel karşılaştırmada özellikle şu noktalar tartışılmalıdır:

- Full NST sonucunda insan bölgesinde stil dokusu belirgin şekilde görülüyor mu?
- Semantic NST sonucunda yüz ve vücut detayları korunmuş mu?
- İnsan ve arka plan sınırında yapay geçiş var mı?
- Stil yalnızca arka planda yeterince güçlü kalmış mı?
- Maske hatası nedeniyle saç, el veya kıyafet kenarlarında kayıp var mı?

B. Metrik Sonuçları

Colab çıktılarından elde edilen metrikler aşağıdaki tabloya yerleştirilmelidir. Değerler geldiğinde tablo doğrudan doldurulabilir.

C. Metrik Sonuçları

Klasik Neural Style Transfer ve önerilen semantik maskeleme destekli yöntem, MSE, PSNR, SSIM ve insan bölgesi üzerindeki Person MSE metriği ile karşılaştırılmıştır.


Tablo VI
FULL NST VE SEMANTIC NST YÖNTEMLERİNİN GENEL GÖRÜNTÜ VE
İNSAN BÖLGESİ METRİKLERİ AÇISINDAN KARŞILAŞTIRILMASI

Yöntem	MSE	PSNR	SSIM	Person MSE	Person PSNR	Person SSIM
Full NST	0.007150	21.457	0.524848	0.007004	21.546	0.538399
Semantic NST	0.005688	22.451	0.614395	0.000187	37.273	0.712137

Bu tabloda beklenen yorum şu şekildedir: Semantic NST sonucunda person MSE değerinin Full NST'ye göre daha düşük olması, insan bölgesinin daha iyi korunduğunu gösterir. MSE ve PSNR değerleri tüm görüntü üzerinden hesaplandığı için arka plandaki bilinçli stil değişimini de cezalandırır. Bu nedenle tüm görüntü MSE'si tek başına yeterli değildir. Projenin amacına en uygun metrik, kişi bölgesine odaklanan person MSE'dir. SSIM ise genel yapısal benzerliğin korunup korunmadığını destekleyici metrik olarak değerlendirilmelidir.

D. Loss Eğrilerinin Yorumu

Optimizasyon sürecinde total loss, content loss, style loss ve tv loss değerleri takip edilmiştir. Loss eğrilerinde genel beklenti, total loss değerinin ilk adımlarda hızlı düşmesi, daha sonra daha yavaş bir yakınsama davranışı göstermesidir. Style loss başlangıçta yüksek olabilir; çünkü hedef görüntü başlangıçta içerik görüntüsüdür ve stil görüntüsünün Gram matrislerine uzak durumdadır. Optimizasyon ilerledikçe hedef görüntü stil özelliklerini taşımaya başlar.



Loss değerlerinin yorumlanmasında dikkat edilmesi gereken nokta, sayısal loss düşüşünün her zaman görsel kaliteyle birebir aynı anlama gelmemesidir. Özellikle style loss çok fazla düşürüldüğünde stil baskınlığı artabilir; fakat içerik yapısı ve insan doğallığı zayıflayabilir. Bu nedenle nicel loss eğrileri görsel inceleme ve person MSE ile birlikte değerlendirilmelidir.

E. Parametre Denemelerinin Değerlendirilmesi

1) *Optimizasyon Adım Sayısı*: Step sayısı arttıkça hedef görüntü stil görüntüsünün Gram matrislerine daha fazla yaklaşır. 80–120 step hızlı testler için yeterli olabilir; ancak stil dokusu zayıf kalabilir. 150–300 step aralığı kalite ve süre açısından daha dengeli sonuç verir. 300'den fazla step ise bazı görsellerde arka plan stilini güçlendirir de çalışma süresini artırır. Ayrıca stil ağırlığı yüksekse fazla step, insan sınırlarında istenmeyen stil sızmalarını daha görünür hale getirebilir.

Bu nedenle final rapor için önerilen yaklaşım, önce 256 × 256 boyutta 80–120 step ile hızlı parametre keşfi yapmak, ardından en iyi bulunan parametreleri 384 × 384 veya 512 × 512 boyutta 150–300 step ile çalıştırmaktır. Bu yaklaşım mühendislik açısından hem hesaplama maliyetini azaltır hem de daha bilinçli parametre seçimi sağlar.

2) *Content Weight*: Content weight değeri arttığında hedef görüntü içerik görüntüsünün VGG19 conv4_2 temsiline daha yakın kalır. Bu durum sahne yapısının korunmasını güçlendirir. Ancak content weight çok yüksek seçilirse stil aktarımı zayıflar ve sonuç görüntü orijinale çok yakın kalır. İnsan koruma amacı zaten semantik maske ile sağlandığı için content weight

değerinin aşırı artırılması gerekli değildir. Bu projede $\alpha = 5$ değeri, stil ve içerik arasında dengeli bir başlangıç noktası olarak kullanılabilir. Eğer sonuçta arka plan fazla bozuluyor veya içerik yapısı kayboluyorsa $\alpha = 10$ gibi daha yüksek değerler denenebilir.

3) *Style Weight*: Style weight değeri, stil görüntüsünün doku ve renk özelliklerinin hedef görüntüye ne kadar güçlü aktarılacağını belirler. $\beta = 100000$ değeri NST uygulamalarında yaygın biçimde görülen yüksek stil katsayılarına benzer şekilde seçilmiştir; çünkü style loss'un ham ölçeği içerik kaybından farklıdır. Style weight düşükse sonuç daha gerçekçi fakat daha az sanatsal olur. Style weight çok yüksekse arka plan güçlü biçimde stilize edilir; ancak insan sınırlarında, saç çevresinde ve ince detaylarda stil sızması görülebilir. Bu nedenle insan korumalı NST için style weight artırılırken blur size ve segmentasyon kalitesi birlikte düşünülmelidir.

4) *Learning Rate*: Adam optimizasyonunda öğrenme oranı 0.03 olarak seçilmiştir. Bu değer hedef görüntünün hızlı güncellenmesini sağlar. Daha yüksek öğrenme oranları hedef görüntüde kararsız renk geçişleri veya gürültü oluşturabilir. Daha düşük öğrenme oranları ise daha stabil ancak daha yavaş yakınsama sağlar. Eğer loss eğrilerinde ani sıçramalar görülürse learning rate 0.01 seviyesine indirilebilir. Eğer loss çok yavaş düşüyorsa 0.03 değeri korunabilir.

5) *Blur Size*: Blur size, insan maskesi ile arka plan arasındaki geçişin doğallığını etkileyen önemli bir parametredir. Küçük blur size değerlerinde kişi sınırı keskin kalır ve sonuçta kes-yapıştır etkisi oluşabilir. Büyük blur size değerlerinde geçiş daha doğal olur; fakat insanın kenar bölgelerine stilize arka plan karışabilir. Özellikle saç, omuz, el ve kıyafet kenarları bu durumdan etkilenebilir. Bu projede 21 değeri dengeli bir seçimdir. Eğer maske sınırları sert görünüyorsa 31 veya 41 denenebilir; eğer insan kenarları fazla stilize oluyorsa 7 veya 11 gibi daha küçük değerler denemelidir.

IX. YÖNTEMİN GÜÇLÜ VE ZAYIF YÖNLERİ

A. Güçlü Yönler

Bu çalışmanın güçlü yönlerinden biri NST yaklaşımında stil aktarımı tüm görüntüye aynı şekilde uygulanmaktadır. Bu durum özellikle insan içeren görüntülerde yüz, saç, kıyafet gibi detaylarının bozulmasına yol açabilmektedir. Bu projede ise DeeplabV3 Resnet50 modeli ile kişi bölgesi başarılı şekilde ayrıştırılmış ve stil aktarımı sonrasında insan bölgesi orjinal görüntüye yakın tutulmuştur. Böylece çıktı görüntüsünde hem sanatsal arka plan etkisi elde edilmiş hem de görselin ana odağı korunmuştur.

Projenin bir diğer güçlü yönü, sıfırdan büyük bir derin öğrenme modeli eğitmeye ihtiyaç duymamasıdır. VGG19 modeli stil ve içerik özelliklerini çıkarmak için, DeepLabV3 modeli ise insan bölgesini tespit etmek için hazır ağırlıklarla kullanılmıştır. Bu durum projeyi donanım açısından daha erişilebilir hale getirmiştir. Özellikle sınırlı GPU kaynağı olan kişiler için bu yaklaşım daha uygulanabilir olmuştur.

Ayrıca kodun sistemli tasarlanması önemli bir avantaj sağlamıştır. Segmentasyon, stil aktarımı, maske yumuşatma, görüntü harmanlama ve metrik hesaplama işlemleri birbirinden

ayrılmıştır. Bu sayede herhangi bir birleşen ileride kolayca değiştirilebilir. Örneğin DeepLabV3 yerine daha güncel bir segmentasyon modeli, VGG19 tabanlı klasik NST yerine ise daha hızlı çalışan bir style transfer modeli entegre edilebilir. Bu açıdan proje yalnızca tek bir çıktı üretmeye yönelik basit bir uygulama değil, geliştirilmeye açık bir şekilde tasarlanmıştır.

B. Karşılaşılan Zorluklar ve Çözüm Yaklaşımı

Proje geliştirme sürecinde karşılaşılan ilk önemli zorluk, klasik NST çıktılarında insan bölgesinin fazla bozulması olmuştur. Stil ağırlığı artırıldığında arka plan daha sanatsal görünse de insan yüzü ve kıyafet kısımları da aynı oranda olumsuz etkilenmiştir. Bu durum projenin temel problemini daha net ortaya çıkarmıştır. Bu probleme karşı çözüm olarak semantik segmentasyon kullanılmış ve insan bölgesi ayrı bir maske ile korunmuştur. Böylece stil aktarımının yalnızca görsel olarak değil, bölgesel olarak da kontrol edilmesi sağlanmıştır.

İkinci önemli zorluk, segmentasyon maskesinin her zaman kusursuz olmamasıdır. Deeplabv3 modeli genel olarak insan bölgesini başarılı şekilde ayırsa da saç, el, ince kıyafet detayları ve arka planla benzer renkteki bölgelerde hatalar oluşabilmektedir. İlk denemelerde maske kenarları sert kaldığı için insan ile stilize arka plan arasında yapay geçişler görülmüştür. Bu sorunu azaltmak için Gaussian blur uygulanarak maske sınırları yumuşatılmıştır. Böylece insan bölgesi ile arka plan arasındaki geçiş daha yumuşak hale getirilmiştir. Ancak bu çözüm tamamen kusursuz değildir. Özellikle saç gibi karmaşık kenar yapılarında daha gelişmiş maskeleme yöntemlerine ihtiyaç duyulabilir.

Üçüncü zorluk, optimizasyon tabanlı NST yönteminin yavaş çalışmasıdır. Bu yöntemde her yeni içerik ve stil görüntüsü çifti için çıktı görüntüsü yeniden optimize edilmektedir. Bu nedenle işlem süresi, görüntü boyutu ve optimizasyon adım sayısına doğrudan bağlıdır. Daha yüksek çözünürlük ve daha fazla step daha kaliteli sonuçlar üretebilse de çalışma süresini artırmaktadır. Bu nedenle projede kalite ve süre arasında denge kurulmaya çalışılmıştır. Parametre denemelerinde 384×384 görüntü boyutu ve orta düzey optimizasyon adımları ile daha dengeli bulunmuştur.

Son olarak, yalnızca görsel kaliteye bakarak karar vermenin yeterli olmamasıdır. Bazı çıktılar görsel olarak başarılı görünse de insan bölgesinde ciddi değişimler oluşabilmektedir. Bu nedenle değerlendirme aşamasında genel MSE, PSNR ve SSIM metriklerinin yanında özellikle insan bölgesini ölçen person MSE metriği de kullanılmıştır. Bu metrik, projenin ana amacı olan insan bölgesini koruma başarısını daha doğrudan göstermiştir. Böylece sonuçlar yalnızca gözle değil, sayısal değerlendirmeye de dayandırılmıştır.

C. Zayıf Yönler ve Sınırlılıklar

Yöntemin en temel sınırlılığı, sistemin başarısının segmentasyon maskesinin direkt bağlı olmasıdır. Eğer DeepLabV3 insan bölgesini eksik veya hatalı tahmin ederse, çıktı da doğrudan bundan etkilenmektedir. Özellikle saç, parmak, arka planla

karişan kıyafet gibi bölgelerinde maske hataları oluşabilir. Bu nedenle yöntem, segmentasyon modelinin güçlü olduğu görüntülerde daha başarılı çalışmaktadır.

İkinci sınırlılık, mevcut sistemin yalnızca person sınıfına odaklanmasıdır. Yani bu çalışma insan içeren görüntüler için tasarlanmıştır. Araba, hayvan veya farklı nesneler otomatik olarak korunmamaktadır. Eğer görüntüde insan dışında korunması istenen başka bir nesne varsa, mevcut sistem bu nesneyi arka plan gibi stilize etmektedir. Bu durum projenin kullanım alanını sınırlandırmaktadır.

Son olarak, optimizasyon temelli NST yaklaşımının gerçek zamanlı kullanım için uygun olmamasıdır. Her görüntü için yeniden optimizasyon yapılması gerektiğinden işlem süresi artmaktadır. Bu durum özellikle web uygulaması veya mobil uygulama gibi hızlı çıktı beklenen sistemlerde dezavantaj oluşturur. Daha hızlı bir yapı için transformer tabanlı güncel stil aktarım modelleri değerlendirilebilir.

X. GELİŞTİRME ÖNERİLERİ VE DEĞERLENDİRMELER

Bu çalışmanın sonraki aşamalarında ilk olarak segmentasyon tarafını geliştirebileceğimi düşünüyorum. DeepLabV3 yerine SegFormer veya Mask2Former tabanlı daha güncel modeller kullanılarak daha hassas maskeler ile daha iyi bir şekilde segmentasyon yapılarak daha iyi bir sonuç almayı hedefliyorum.

İkinci olarak sistem yalnızca insan bölgesini korumak yerine farklı nesne sınıflarını da destekleyecek şekilde genişletilebilir. Kullanıcı arayüzüne korunacak nesne seçimi eklenerek kişi, araba, hayvan veya belirli nesnelerin stilinin aktarımından korunması sağlanabilir. Böylece proje yalnızca portre fotoğrafları için değil, daha genel amaçlı semantik style transfer uygulamaları için de kullanılabilir hale gelir.

Üçüncü olarak işlem süresi azaltılabilir. Mevcut sistem optimizasyon tabanlı çalıştığı için her yeni görüntüde yeniden hesaplama yapmaktadır. Gelecekte transformer tabanlı style transfer modelleri veya difüzyon tabanlı görüntü düzenleme yaklaşımları denenebilir. Bu sayede daha kısa sürede çıktı üretilebilen bir sistem kurulabilir.

Dördüncü olarak maske sınırları için yalnızca Gaussian blur yerine alpha matting gibi daha gelişmiş yöntemler kullanılabilir. Bu yöntemler özellikle insan ile arka plan arasındaki geçiş bölgelerinde daha doğal sonuçlar üretebilir. Böylece stilize arka plan ile korunan insan bölgesi arasındaki yapaylık azaltılabilir.

Kullanıcı arayüzü tarafı geliştirilebilir. Streamlit uygulamasına loss grafikleri, metrik tablosu, maske görselleştirmesi ve difference map çıktıları otomatik olarak eklenebilir. Böylece kullanıcı yalnızca son görseli değil, modelin hangi bölgeleri ne kadar değiştirdiğini de daha kolay analiz edebilir.

Son olarak parametre seçimi otomatik hale getirilebilir. Content weight, style weight, learning rate, blur size ve step sayısı gibi değerler çıktıyı önemli ölçüde etkilemektedir. Bu nedenle ileride sistem, farklı parametre kombinasyonlarını deneyerek en dengeli sonucu otomatik önerecek şekilde geliştirilebilir.

XI. SONUÇ

Bu çalışmada, insan bölgesini korumaya odaklanan bir NST sistemi geliştirilmiştir. Klasik NST yaklaşımında stil tüm görüntüye uygulandığı için insan fotoğraflarında yüz, vücut, saç gibi detayları bozulabilmektedir. Bu problemi azaltmak amacıyla Deeplabv3 ve resNet50 modeli ile kişi maskesi çıkarılmış, VGG19 tabanlı NST ile görüntü ve son aşamada maske tabanlı semantik birleştirilmiş ve uygulanmıştır.

Çalışmanın matematiksel temeli içerik kaybı, stil kaybı, Gram matrisi, toplam varyasyon kaybı ve maske tabanlı harmanlama işlemlerine dayanmaktadır. VGG19 ağı, içerik ve stil özelliklerini çıkarmak için kullanılmıştır. DeepLabV3 modeli ise insan bölgesini belirleyerek stil aktarımının daha mantıklı yapılmasını sağlamıştır. Bu yönüyle proje, yalnızca bir stil transfer uygulaması değil, semantik segmentasyon ve optimizasyon tabanlı görüntü üretimini birleştiren bir çalışma olmuştur.

Deneysel değerlendirmede MSE, PSNR, SSIM ve person mse metrikleri kullanılmıştır. Özellikle person mse değeri, projenin temel hedefi olan insan bölgesini koruma başarısını ölçmek için önemli olmuştur. Elde edilen sonuçlar, semantik maskeleme destekli yöntemin klasik Full NST yöntemine göre insan bölgesini daha başarılı şekilde koruduğunu göstermiştir. Bu sonuç, önerilen yaklaşımın yalnızca görsel olarak değil, sayısal metriklerde de iyi sonuç vermiştir.

Parametre denemeleri sonucunda görüntü boyutu, optimizasyon adım sayısı, content weight, style weight, learning rate ve blur size değerlerinin çıktı üzerinde belirgin etkisi olduğu görülmüştür. Daha yüksek stil ağırlığı arka planı daha sanatsal hale getirirken, aşırı yüksek değerler görüntüde bozulmalara neden olabilmektedir. Benzer şekilde daha fazla optimizasyon adımı kaliteyi artırabilse de işlem süresini yükseltmekteydi. Bu nedenle proje kapsamında kalite, işlem süresi ve insan bölgesinin korunması arasında dengeli bir yapı kurulmaya çalışılmıştır.

Geliştirme sürecinde önemli kazanımlardan biride, hazır derin öğrenme modellerinin doğru şekilde birleştirildiğinde özgün bir probleme çözüm üretebilmesidir. Bu çalışmada VGG19, Deeplabv3, görüntü maskeleme, loss fonksiyonları, metrik hesaplama ve görsel analiz adımları birlikte kullanılmış ve başarıya ulaşılmıştır.

Gelecekte daha güçlü segmentasyon modelleri, hızlı style transfer ağları ve daha gelişmiş maske yumuşatma teknikleri kullanılarak sistemin başarısı artırmayı hedefliyorum. Buna rağmen mevcut haliyle çalışma, klasik nst yaklaşımının insan odaklı görüntülerdeki önemli bir eksikliğini azaltmaktadır.

KAYNAKLAR

- [1] L. A. Gatys, A. S. Ecker, and M. Bethge, "Image style transfer using convolutional neural networks," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 2414–2423.
- [2] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," in *International Conference on Learning Representations (ICLR)*, 2015.
- [3] L.-C. Chen, G. Papandreou, F. Schroff, and H. Adam, "Rethinking atrous convolution for semantic image segmentation," arXiv preprint arXiv:1706.05587, 2017.

Semantic NST: Person Preserved, Background Styled



Şekil 4. Almış olduğumuz deneme çıktısı bu kısımda Sayın Ozanımız Neşet Ertaş'ın bulunduğu konum korunmuş arka planda kalan kısımlar ise Van Gough'un eserinden stilize edilmiş ve başarıyla ulaşılmıştır.

- [4] J. Johnson, A. Alahi, and L. Fei-Fei, "Perceptual losses for real-time style transfer and super-resolution," in *European Conference on Computer Vision (ECCV)*, 2016, pp. 694–711.
- [5] Y. Deng, F. Tang, W. Dong, C. Ma, X. Pan, L. Wang, and C. Xu, "StyTr²: Image style transfer with transformers," in *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR)*, 2022, pp. 11326–11336.
- [6] PyTorch TorchVision, "VGG19 model documentation," Available: <https://docs.pytorch.org/vision/main/models/generated/torchvision.models.vgg19.html>
- [7] PyTorch TorchVision, "DeepLabV3 ResNet50 model documentation," Available: https://docs.pytorch.org/vision/main/models/generated/torchvision.models.segmentation.deeplabv3_resnet50.html
- [8] B. İlyas, "Semantic Style Transfer with Person Preservation," GitHub repository, 2026. Available: <https://github.com/bilyas0/Semantic-Style-Transfer>